

aula de eng de dados

topico 1

problemas de granularidade, como esses dados pdem ser normalizados ? pois cada um tem uma fonte.

o uso de etl como podemos automtatizar esses dados com um certo periodo de tempo usando um script, como podemos para uma parcela. podemos usar esse script que podem ser ativados dependendo da necessidade, podendo ser diario, semanal ou mensal.

como esses dados podem ser consumidos.

usando powerbi, com interfaces como um streamlit da vida.

datadriviem onde por exemplo marketing, produto e gestão podem usar esses dados de forma direta.

as decisoes são tomadas com base nos dados !!! temos como ponto de contraste nesse caso uma complexidade das querys. onde fica mais dificil pelo gargalo dos dados quesão produzidos. gerando um problema na pipeline inicial. isso acontece pois como automatizamos nosso processo temos esse contrasate e precisamos lidar com essa alta complexidade dos dados.

DATA WAREHOUSE

o foco do datawarehouse seria um consumo dos nossos dados pois os foco não e a transação mas o consumo dos dados pelo atp

datascience workflow

datalake

onde não usamos uma estruturação dos dados nesse caso vamos usar esse tipo de arquitetura, para trabalhar. onde temos dados brutos e imcompleto focado para cientistas de dados terem liberdades para usar modelos de ml

isso aplica ELT

abordagem é diferente onde vamos transformar depois

big data

usamos os 4vs



precisamos mesmo com essa grande quantitade ter a veracidade dos dados e confiabilidade dos dados.

data streaming

fluxo continuo de dados como nesse caso podemos pegar snapshots de um bloco de dados para pegar e armazenar os dados para nosso datawarehouse

usamos os streams para gerar e aplicar nosso topico para as nossas tabelas de etl. com isso removemos a granularidade no contexto de big data

Data Streaming

// Introdução à Engenharia de Dados

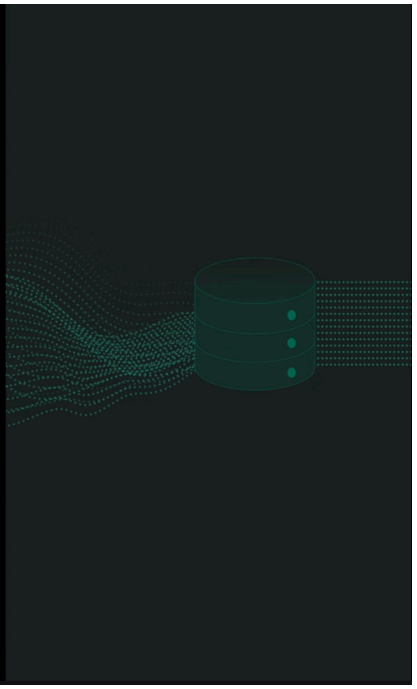
Fluxo Contínuo de Dados

>> Data streaming refere-se ao processamento contínuo de dados em tempo real, permitindo que as informações sejam analisadas e utilizadas à medida que são geradas, em vez de serem armazenadas primeiro.

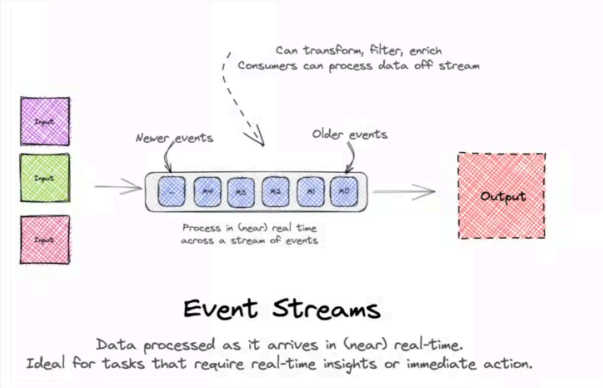
>> Comunicação assíncrona via Publish/Subscribe (Pub/Sub).

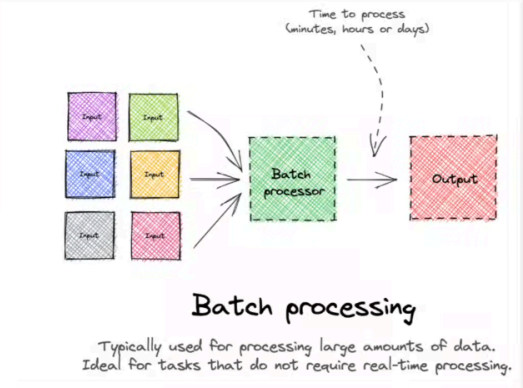
>> Como funciona: Os produtores de dados publicam mensagens em um canal, enquanto os consumidores se inscrevem para receber essas mensagens em tempo real.

>> Ferramenta popular: Apache Kafka.



// Introdução à Engenharia de Dados





v[dev]

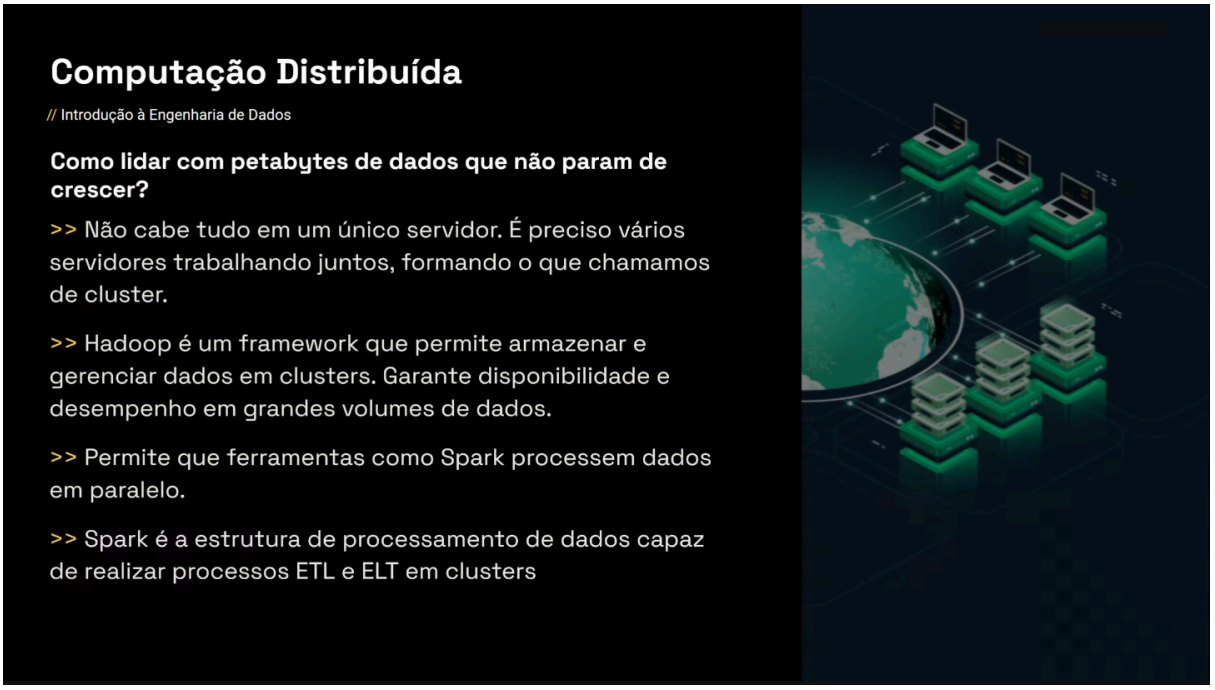
usamos por demanada nesse caso quanto mais ids e avisos usamos a atualização em real-time.

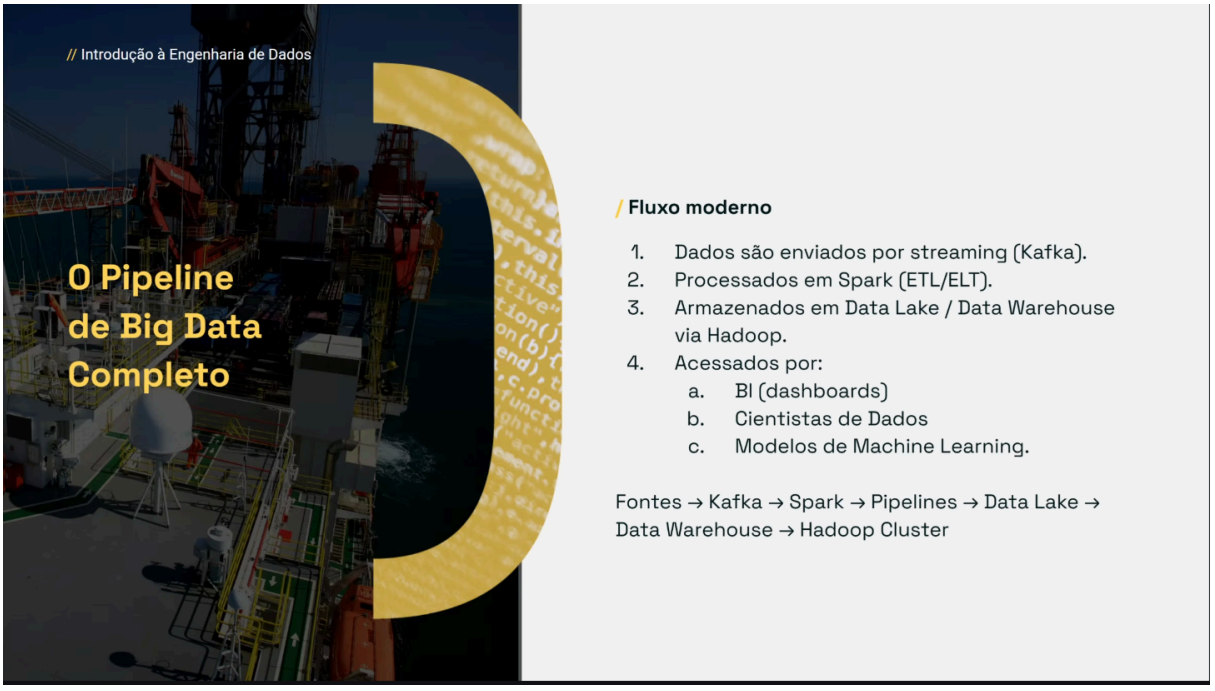
batch seria usando o apache kafka eo event straeams seria usando o airflow. nesse caso podemos definir para o event streams de hora em hora

um caso de estudo seria o snapshot

computação distribuida hadoop → onde vamos usar varios clusters para gerar disponibilidade de grande volumes de dados. ele dá suporte para o spark trabalhar de forma em paralelo. usamos para ter redundancia dos dados e segurança.

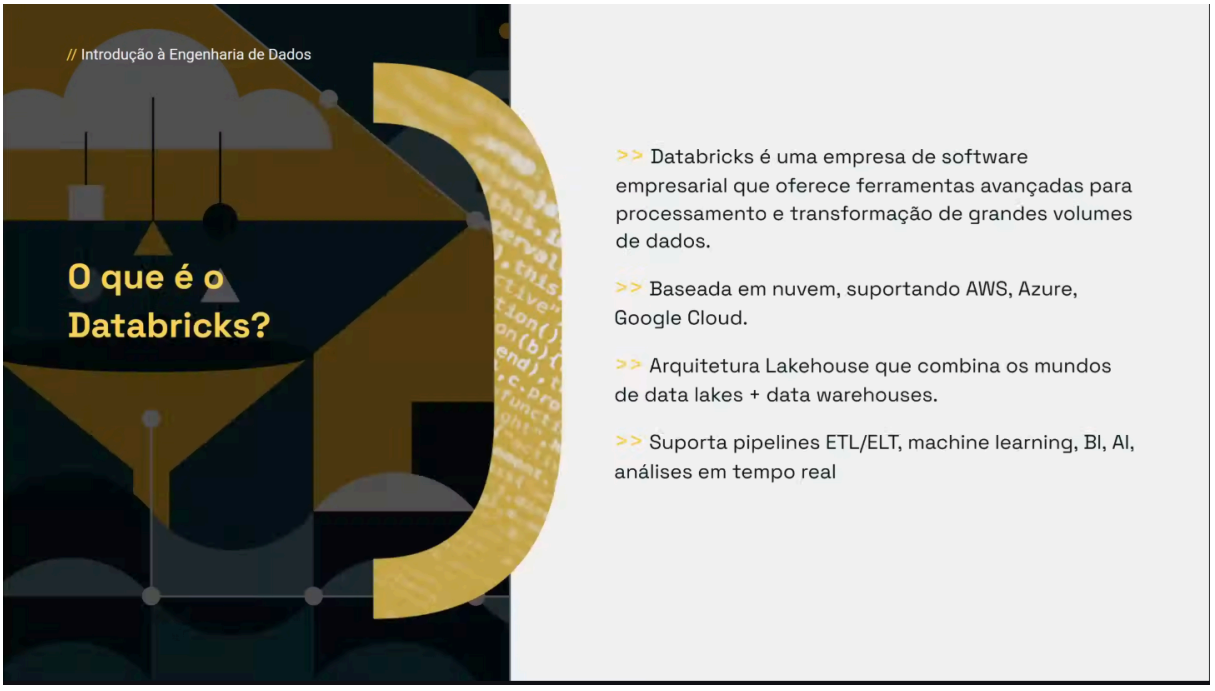
uma duvida computação distribuida poderia ser usada em um aws ec2 ou um gcp

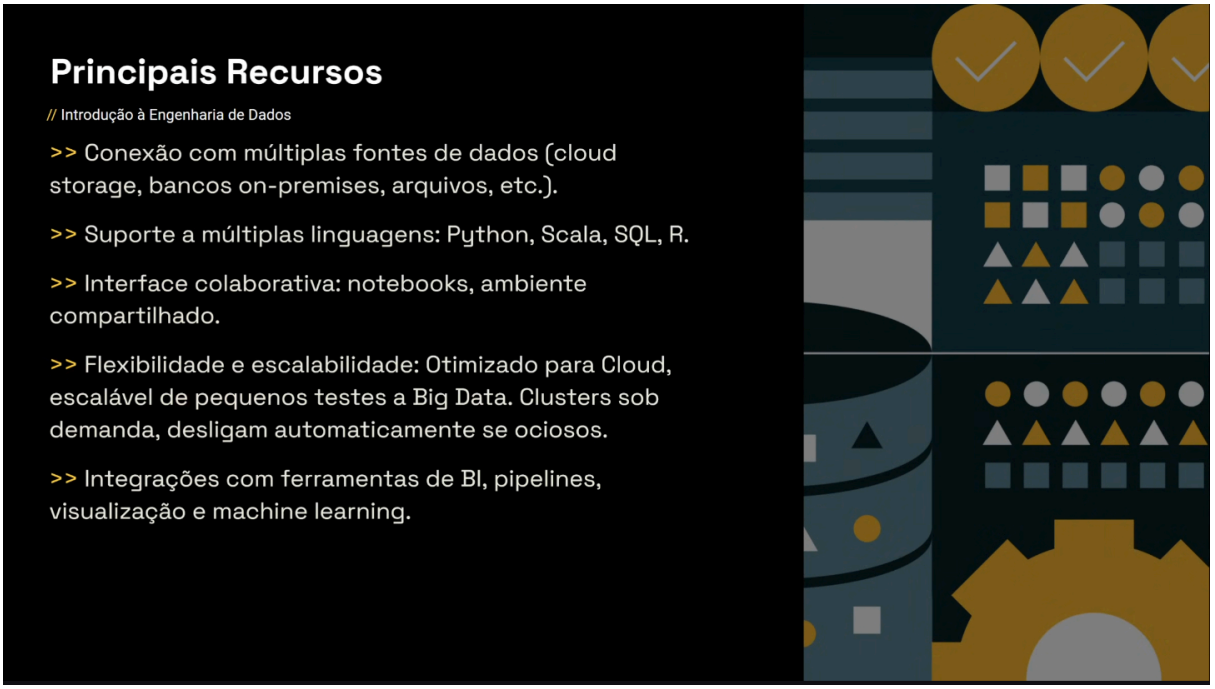


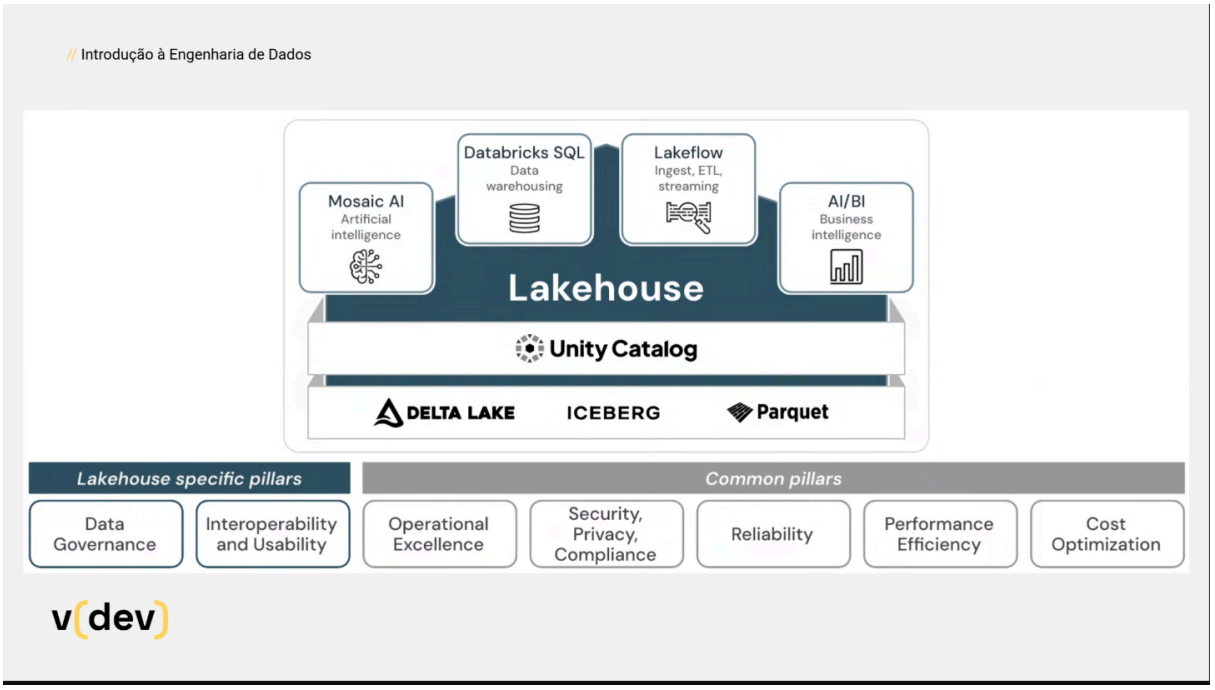


ferramentas

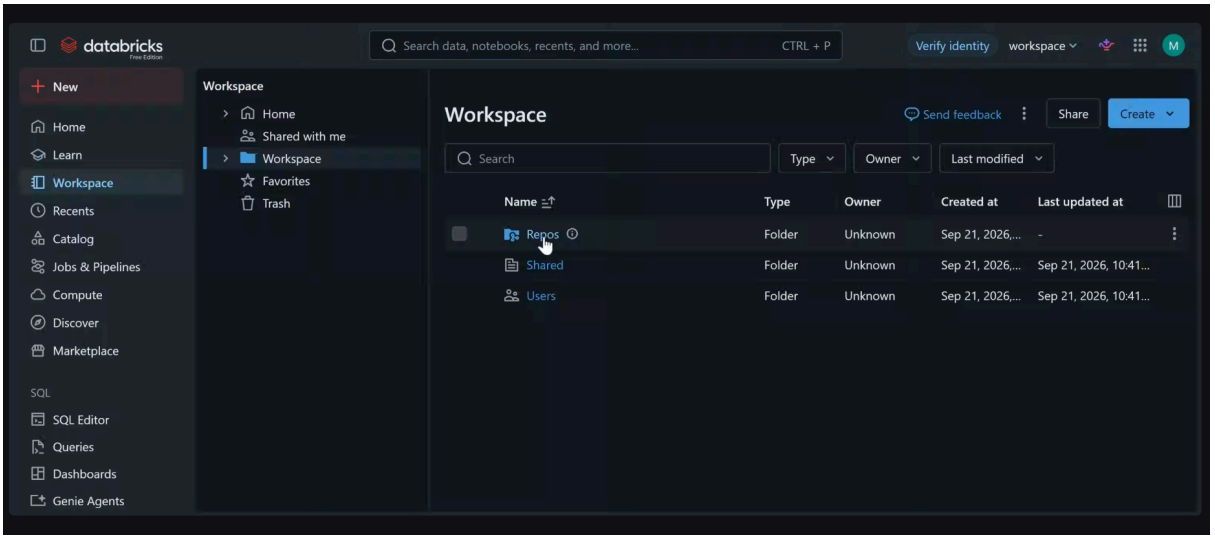
databricks onde podemos fazer tudo isso para a parte de processamento de dados, onde vamos apenas processar e que vai ser usado para armazenar.



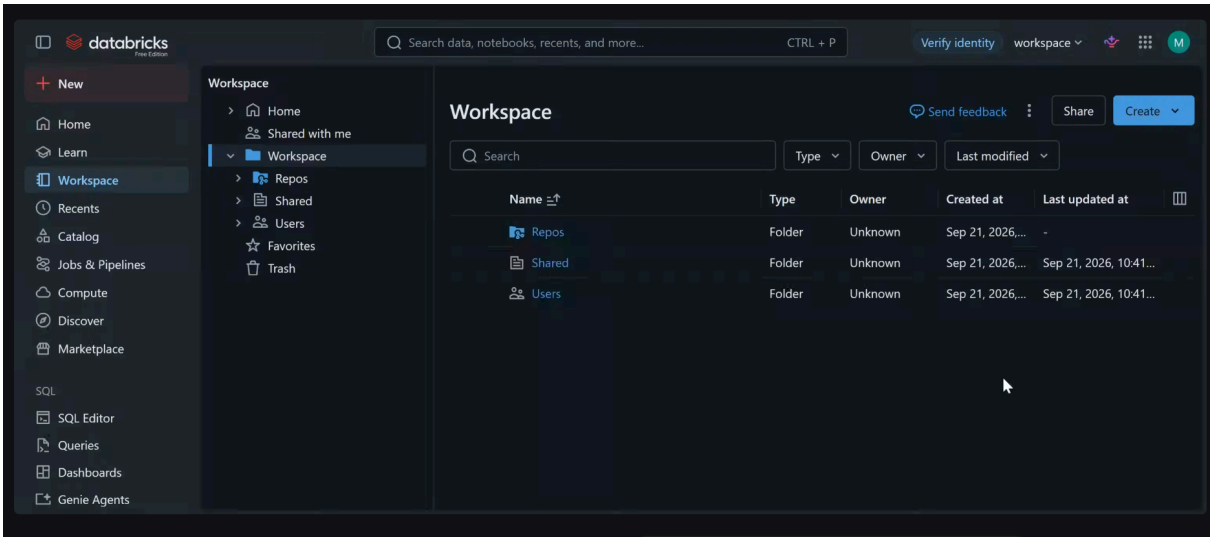




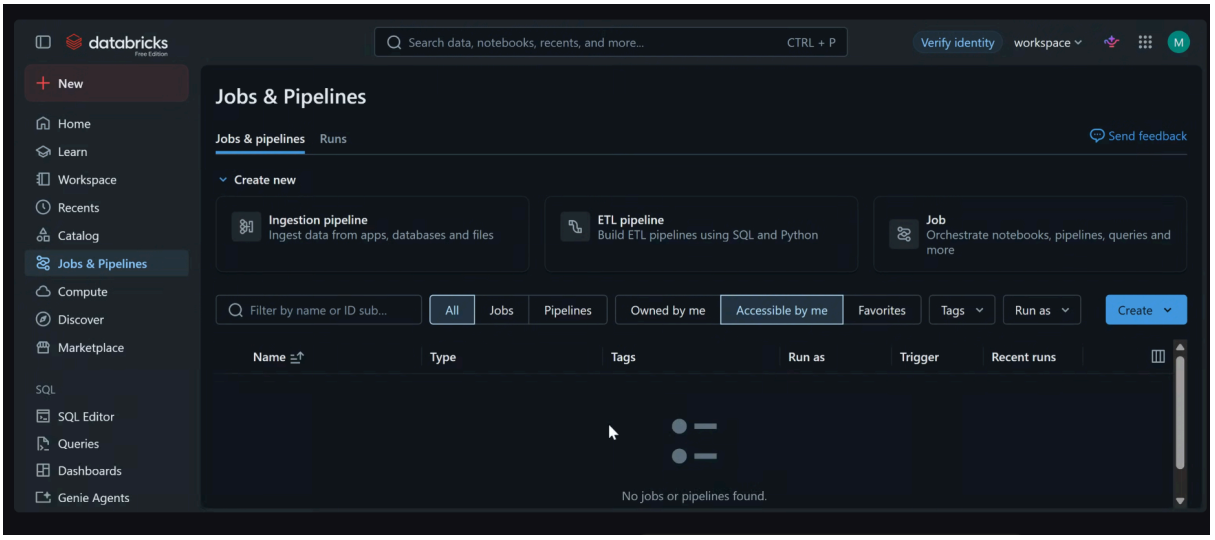
podemos criar versoes da nossa tabela, conseguimos fazer um branch dessa tabela onde evita armazenar dados errados caso tenha acontecido um erro.



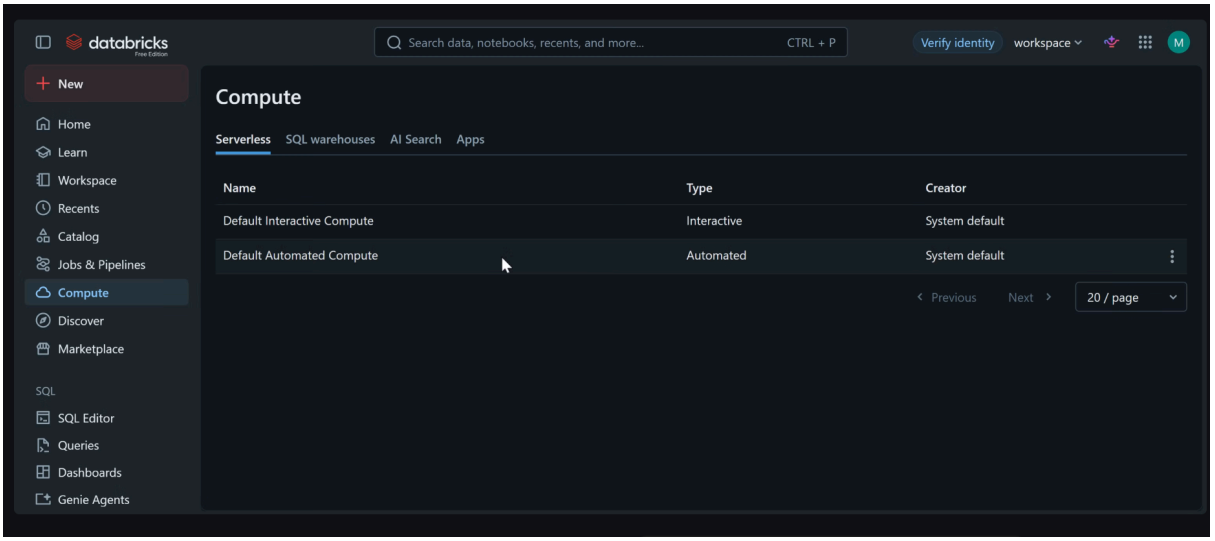
normalmente quando usamos para compartilhar os notebooks de trabalho



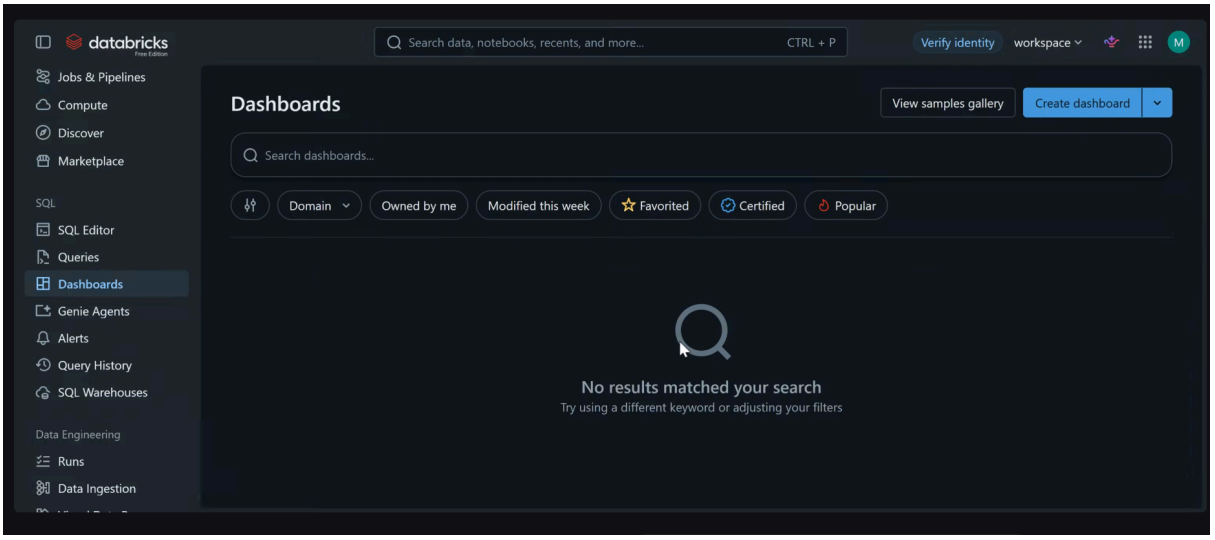
onde vamos criar nossos etl



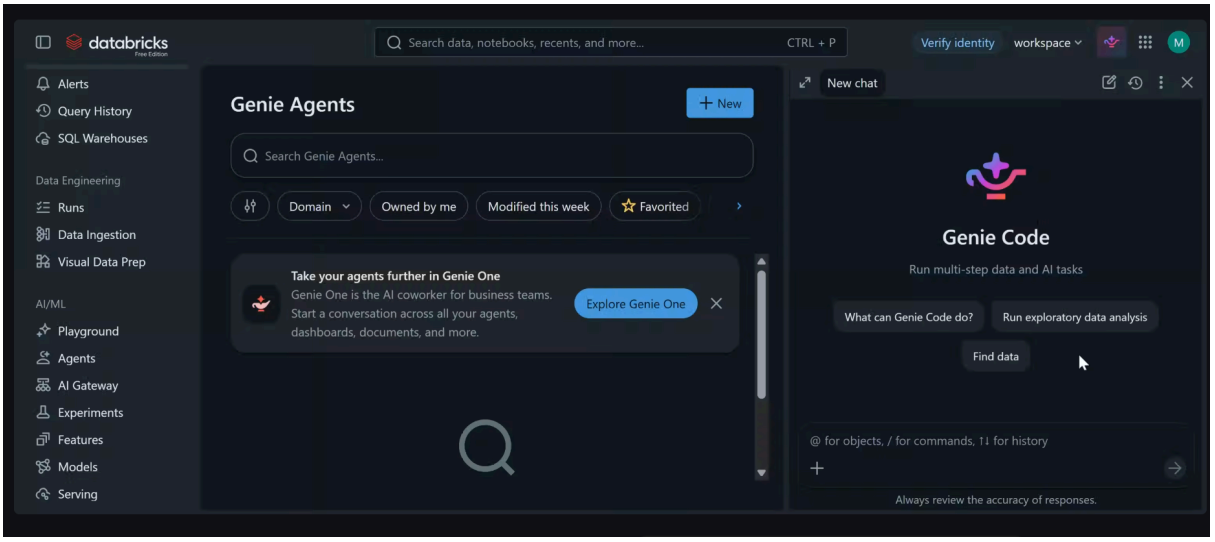
versão dos nossos clusters



dashboard



usar para triar duvidas ele foi pretreinado para o databricks



podemos fazer em partes nesse caso fazer usar os notebooks para a leitura de dados cruzs, fazer uso de scripts para fazer a parte de etl ou elt, fazer o uso de gcp ou aws para amazenar os dados.

aula 2 data lake

aula de eng